

ДИСЦИПЛИНА	Модели и методы предиктивной аналитики
	(полное наименование дисциплины без сокращений)
ИНСТИТУТ	информационных технологий
КАФЕДРА	Прикладной математики
	(полное наименование кафедры)
ВИД УЧЕБНОГО МАТЕРИАЛА	Материалы для практических/семинарских занятий
	(в соответствии с пп. 1-11)
ПРЕПОДАВАТЕЛЬ	Парамонов Александр Александрович
	(фамилия, имя, отчество)
СЕМЕСТР	7, 2026-2027
	(указать семестр обучения, учебный год)

ПРАКТИЧЕСКОЕ ЗАДАНИЕ 1. ПАРСИНГ ДАННЫХ

В рамках работы студент должен сформировать три самостоятельных набора данных: временной ряд, многомерный структурированный набор и текстовый корпус.

Этапы выполнения задания.

Этап 1 - исследование и выбор подходящих источников данных

На этом этапе студент должен определить, какие именно показатели будут анализироваться, оценить доступность данных через открытые API, изучить ограничения сервисов (лимиты запросов, необходимость регистрации, формат возвращаемых данных, доступность исторических данных).

В большинстве случаев требуется регистрация на официальном сайте сервиса и получение персонального API-ключа. Этот ключ используется для аутентификации при выполнении запросов.

Важно заранее изучить документацию API: структуру URL-запросов, обязательные и необязательные параметры, формат ответа, ограничения частоты обращений («rate limits» - в англоязычной документации API), требования к формату даты и единицам измерения.

При формировании набора *временного ряда* необходимо выбрать источник, предоставляющий данные, упорядоченные во времени. Временной ряд должен содержать четко определённую временную метку (дата или дата и время) и числовой показатель. Важно определять по временной метке частоту снятия данных. Ключевыми требованиями к собираемым данным являются непрерывность по частоте снятия и наличие общего объёма ряда не менее 3000 точек.

Источники временных рядов чаще всего предоставляют экономические или финансовые, метеорологические или эпидемиологические данные, возможны иные сферы источников данных (спорт, экология, биология и т.д.).

При формировании многомерного набора данных необходимо получить данные, содержащие несколько признаков (переменных) для ряда объектов. Как правило, это панельные данные, включающие измерения по странам, регионам или годам.

При работе с *многомерными данными* необходимо обеспечить корректность типов переменных (числовые, категориальные), удалить дубликаты, проверить наличие пропусков и при необходимости выполнить предварительную очистку. Минимальный набор должен включать не менее 8 признаков и достаточное число наблюдений для статистического анализа, порядка 1000 объектов наблюдений. Объём многомерных данных (количество признаков на количество объектов) зависит от их соотношения и чистоты данных. При согласовании с семинаристом возможны изменения по объёму набора данных.

Формирование текстового набора данных предполагает получение корпуса текстов с сопутствующими метаданными. Источниками могут

выступать новостные и медиа-API. При обработке текстовых данных необходимо обеспечить очистку текста от HTML-тегов, специальных символов, дубликатов публикаций и пустых записей. Важно сохранить метаданные (дата, источник, ссылка), поскольку они могут использоваться для временного анализа или тематической классификации.

Наборы данных у всех студентов должны быть различными.

Этап 2 - разработка скриптов для парсинга

Этап разработки скриптов предполагает реализацию программного кода на Python с использованием библиотек requests для выполнения HTTP-запросов и pandas для структурирования данных.

Необходимо обрабатывать возможные ошибки соединения, проверять статус ответа сервера (код 200), учитывать ограничения по количеству запросов и при необходимости реализовывать задержки между обращениями. Ответы API в формате JSON преобразуются в словари или DataFrame.

Для временных рядов требуется приведение даты к формату datetime и сортировка по времени; для многомерных данных — корректная типизация признаков; для текстов — сохранение строк в кодировке UTF-8.

Этап 3 – сохранение данных

Сохранение данных должно осуществляться в удобных для дальнейшего анализа форматах. Для временных и многомерных данных предпочтителен формат CSV, поскольку он легко импортируется в аналитические системы. Текстовые данные могут сохраняться в JSON (для сохранения вложенной структуры) или CSV (если структура упрощена). Обязательно необходимо зафиксировать источник данных и дату загрузки.

Этап 4 – подготовка отчёта

В отчёте подробно описывается процесс выбора API, параметры запросов, структура полученных данных, этапы очистки и преобразования. Также необходимо указать ограничения источников, возможные проблемы (пропуски, неполнота текстов, различия в единицах измерения) и сделать вывод о пригодности данных для последующего построения моделей предиктивной аналитики.

После выполнения задания у студента должны быть три отдельных набора данных, готовых для дальнейшего анализа и отчёт о проделанной работе.

ПРАКТИЧЕСКОЕ ЗАДАНИЕ 2. ПОСТРОЕНИЕ МОДЕЛИ РЕКОМЕНДАЦИЙ

Основная цель задания заключается в освоении методов интеллектуального анализа данных и построения систем рекомендаций, которые широко используются в современных цифровых сервисах: интернет-магазинах, стриминговых платформах, социальных сетях и образовательных системах.

Этап 1 - сбор данных для рекомендательной системы

Студенту предлагается самостоятельно подобрать подходящий набор данных, содержащий информацию о взаимодействии пользователей с объектами из первой практики. В качестве объектов могут выступать фильмы, книги, товары, музыкальные композиции, игры или любые другие сущности, по которым можно формировать персонализированные рекомендации. В качестве примеров таких наборов могут служить: MovieLens, Amazon Product Reviews, Goodbooks-10k и т.д. Студент может использовать и другие источники данных, если они подходят для решения задачи рекомендаций и находятся в открытом доступе.

При выборе набора данных важно учитывать несколько факторов. Во-первых, данные должны содержать идентификаторы пользователей и объектов, а также информацию о взаимодействии между ними. Это могут быть оценки, лайки, просмотры, покупки, клики или история прослушивания. Во-вторых, желательно наличие большого количества записей, поскольку рекомендательные алгоритмы показывают более качественные результаты на объемных данных. В-третьих, необходимо оценить полноту и качество данных: отсутствие большого числа пропусков, корректность идентификаторов и наличие достаточного числа взаимодействий между пользователями и объектами.

Этап 2 – обработка данных

После загрузки данных выполняется этап предварительной обработки. Студент должен провести очистку данных, удалить дубликаты, обработать пропущенные значения и привести данные к единому формату. Например, если оценки представлены в разных диапазонах, может потребоваться нормализация значений. Также необходимо выделить основные признаки, используемые в рекомендательной системе. Как правило, это столбцы `user_id`, `item_id` и `rating`. Дополнительно могут использоваться временные метки, категории объектов, текстовые описания или теги.

Особое внимание следует уделить анализу структуры данных перед построением модели. Желательно определить количество уникальных пользователей и объектов, распределение оценок, среднее число оценок на пользователя и степень разреженности матрицы взаимодействий.

Разреженность является одной из ключевых особенностей рекомендательных систем, поскольку большинство пользователей

взаимодействует только с небольшой частью объектов. Для этого рекомендуется строить статистические сводки и визуализации: гистограммы оценок, распределения популярности объектов и активности пользователей.

Этап 3 – построение рекомендательной модели

В работе предлагается использовать методы коллаборативной фильтрации, либо подходы на основе содержимого объектов. Коллаборативная фильтрация основана на анализе поведения пользователей и поиске сходства между ними или между объектами. Один из наиболее распространённых методов - матричное разложение, например сингулярное разложение матриц (SVD).

При использовании SVD формируется матрица взаимодействий пользователей и объектов. Затем алгоритм разлагает её на несколько матриц меньшей размерности, позволяя выявить скрытые зависимости между предпочтениями пользователей и характеристиками объектов. Описанный алгоритм и его детали должны быть реализованы студентом самостоятельно.

Если студент выбирает подход на основе содержимого (content-based), то рекомендации строятся не на поведении других пользователей, а на характеристиках самих объектов. Например, для фильмов можно использовать жанры, описания, ключевые слова или актёрский состав. В этом случае модель должна анализировать предпочтения пользователя и предлагает объекты, похожие на те, которые ему уже понравились.

В качестве помощи к реализации такого подхода рекомендуется реализовать такой метод через TF-IDF-векторизацию текстов, косинусное сходство и методы обработки естественного языка. Описанный алгоритм и его детали должны быть реализованы студентом самостоятельно.

Для обучения рекомендательной модели данные обычно разделяются на обучающую и тестовую выборки. После обучения системы необходимо сформировать рекомендации для пользователей. Необходимо определить топ-3, топ-5 и топ-10 рекомендаций - список из нескольких наиболее подходящих объектов. Сформированные списки сравнить и назвать причины такого расположения рекомендаций в списке.

В отчёте рекомендуется показать примеры рекомендаций для разных пользователей и проанализировать, насколько они выглядят логично и персонализировано, объяснить почему.

Этап 4 – оценка и интерпретация результатов

Для оценки качества списков рекомендаций, помимо специальных оценок для рекомендательных систем, необходимо использовать классические Precision и Recall. Precision показывает долю действительно релевантных объектов среди рекомендованных системой. Recall характеризует, насколько полно система смогла найти интересные пользователю объекты. Результаты таких оценок необходимо сравнить с результатами специализированных оценок для рекомендательных систем и объяснить их сходство или различие.

Студенту необходимо не просто вычислить метрики, а проанализировать сильные и слабые стороны модели. Например, необходимо определить, как влияет количество скрытых факторов в SVD, насколько чувствительна модель к разреженности данных, какие пользователи получают наиболее точные рекомендации и почему, и т.п.

Желательно рассмотреть проблему «холодного старта», когда для новых пользователей или новых объектов отсутствует достаточная информация.

Этап 5 – подготовка отчёта

В заключительной части работы студент должен подготовить полноценный отчёт. В отчёте необходимо описать источник данных, этапы их обработки, используемые библиотеки Python, структуру модели, методы оценки качества и результаты экспериментов. Также следует привести примеры полученных рекомендаций, визуализации и итоговые выводы о качестве построенной системы.

Для реализации практической работы рекомендуется использовать язык Python и специализированные библиотеки: pandas для обработки данных, numpy для математических вычислений, scikit-learn для подготовки признаков и оценки моделей, а также matplotlib или seaborn для визуализации результатов. Использование Jupyter Notebook позволит удобно документировать ход выполнения работы и совмещать программный код с аналитическими комментариями.

ПРАКТИЧЕСКОЕ ЗАДАНИЕ 3. ОБРАБОТКА ТЕКСТА

Цель практического занятия состоит в том, чтобы научиться выполнять полный цикл базовой обработки и анализа текстовых данных: от первичной очистки текста до выявления ключевых слов, эмоциональной окраски, сущностей и тематической принадлежности текста. В рамках работы студент должен не просто применить готовые инструменты, а понять логику каждого этапа обработки текста и уметь объяснить, зачем он выполняется и как влияет на итоговый результат анализа.

На первом этапе необходимо выбрать или подготовить текстовые данные для анализа. Это могут быть новости, отзывы пользователей, комментарии, статьи, описания товаров, сообщения из социальных сетей, фрагменты научных текстов или другие текстовые массивы. Важно, чтобы объём данных был достаточным для анализа: один короткий текст может быть использован для демонстрации алгоритма, но для полноценного частотного анализа, определения тональности и тематической классификации лучше использовать набор текстов. Данные желательно представить в виде таблицы, например в формате CSV или Excel, где одна строка соответствует одному текстовому документу, отзыву или сообщению.

Далее – предварительная обработка текста. Она необходима для приведения текстовых данных к единому и удобному для анализа виду. Сначала выполняется токенизация, то есть разбиение текста на отдельные элементы. В зависимости от задачи токенами могут быть слова, предложения или отдельные фразы. Например, если анализируется частотность слов, текст разбивается на слова; если требуется анализ структуры текста, можно дополнительно разбивать его на предложения. На этом этапе важно учитывать особенности языка: для русского текста, что является рекомендуемым языком для текстовой обработки, нужно корректно обрабатывать окончания, знаки препинания, сокращения и сложные слова.

После токенизации проводится очистка текста. Из текста удаляются знаки препинания, лишние пробелы, специальные символы, HTML-теги, ссылки, эмодзи, номера телефонов, адреса электронной почты и другие элементы, которые не несут смысловой нагрузки для анализа. Также текст обычно приводится к нижнему регистру, чтобы слова «Данные», «данные» и «ДАННЫЕ» воспринимались как один и тот же термин.

Студенту необходимо не забывать про удаление стоп-слов – часто встречающиеся служебные слова, которые обычно не помогают определить смысл текста. К ним относятся предлоги, союзы, частицы и местоимения, например: «и», «в», «на», «но», «это», «как», «что». Удаление стоп-слов позволяет сосредоточиться на содержательных терминах. Однако важно понимать, что список стоп-слов зависит от задачи. Например, при анализе тональности некоторые слова, такие как «не», нельзя удалять бездумно, потому что они могут менять смысл высказывания: «хорошо» и «не хорошо» имеют противоположную эмоциональную окраску.

После очистки текста выполняются стемминг и лемматизация.

Стемминг заключается в отсечении изменяемых частей слова и приведении его к условной основе. Например, слова «анализировать», «анализировал», «анализируемый» могут быть сведены к общей основе. Лемматизация является более точным методом: она приводит слово к его нормальной словарной форме. Например, «данными», «данных», «данные» будут приведены к форме «данные». Для русского языка лемматизация часто предпочтительнее стемминга, поскольку позволяет сохранить более корректную языковую форму слова.

Далее необходимо провести частотный анализ – определить, какие слова чаще всего встречаются в анализируемом корпусе текстов. В рамках практики необходимо выявить топ-20 наиболее частотных слов. Результат можно представить в виде таблицы, где указаны слово и количество его появлений, а также в виде графика, например, столбчатой диаграммы. При этом студент должен уметь интерпретировать результат: высокая частотность слова не всегда означает его смысловую важность, поэтому результаты нужно анализировать с учётом контекста.

Следующий этап анализа – определение эмоциональной окраски текстов. Необходимо классифицировать тексты как позитивные, негативные или нейтральные. Для этого можно использовать готовые библиотеки, словарные подходы или заранее обученные модели машинного обучения. Например, для отзывов пользователей позитивными могут считаться тексты с высокой оценкой продукта, негативными – жалобы и критические сообщения, нейтральными – информационные или описательные тексты. В отчёте важно указать, какой метод использовался, какие классы тональности были выделены и насколько корректно модель справилась с анализом.

Далее студенту требуется выполнить выделение ключевых сущностей. Этот этап предполагает поиск в тексте имён людей, названий организаций, компаний, географических объектов, дат, событий и других значимых элементов. Например, в новостном тексте могут быть выделены фамилии политиков, названия стран, городов, организаций и конкретные даты.

Завершающим аналитическим этапом является определение основных тем текста и его классификация. На основе частотного анализа, ключевых слов, выделенных сущностей и общего содержания необходимо определить, к какой тематической области относится текст: спорт, информационные технологии, экономика, образование, политика, медицина, культура и так далее. Классификация может быть выполнена вручную на основе анализа признаков или с использованием моделей машинного обучения. Важно, чтобы студент объяснил, почему текст был отнесён именно к выбранной категории.

Это же задание необходимо провести и в прогнозно-аналитической плат-форме для текстового анализа данных PolyAnalyst. Для демонстрации результатов, полученных в PolyAnalyst отдельно настроить дашборд с выводом результатов основных элементов. Полученные результаты в обеих реализациях – сравнить.

В результате выполнения практической работы студент должен

представить реализацию всех этапов обработки текста, результаты анализа и краткую интерпретацию полученных данных. Отчёт должен включать описание исходных данных, применённые методы предобработки, результаты частотного анализа, определение эмоциональной окраски, список выявленных сущностей, тематическую классификацию текста и выводы. Желательно дополнить отчёт таблицами, графиками и примерами обработанных текстов до и после предобработки. Полученные результаты в обеих реализациях – сравнить.

ПРАКТИЧЕСКОЕ ЗАДАНИЕ 4. АНАЛИЗ ВРЕМЕННОГО РЯДА

Цель практической работы состоит в том, чтобы провести комплексный анализ временного ряда, полученного студентом в первой практической работе. Основное внимание уделяется не просто построению графика исходных данных, а выявлению внутренней структуры временного ряда: быстрых и медленных изменений, скрытых или почти периодов, а также участков с различным характером роста.

Предполагается, что студент использует результат первой практической работы, т.е. временной ряд, готовый для анализа. После загрузки данных следует построить первичный график временного ряда, чтобы визуально оценить его динамику, наличие тренда, резких скачков, выбросов, сезонности или повторяющихся колебаний.

В первую очередь требуется разделить быстрые и медленные движения временного ряда на основе теории пропорций. Под медленными движениями понимаются долгосрочные изменения, отражающие общий тренд. Быстрые движения связаны с локальными колебаниями, шумом, краткосрочными изменениями и резкими отклонениями от общей тенденции. Разделение быстрых и медленных движений следует проводить на основе теории пропорций.

После разделения быстрых и медленных движений временного ряда, необходимо проанализировать данные на предмет наличия почти периодов - значений, близких к периодическим. Для выявления таких закономерностей строится обобщённая сдвиговая функция. Её смысл заключается в сравнении временного ряда с самим собой, но сдвинутым на разные значения лага. Если при некотором сдвиге форма ряда хорошо совпадает с исходной, это может указывать на наличие почти периода.

После построения обобщённой сдвиговой функции необходимо выполнить анализ срезов. Это означает, что студент должен определить те значения сдвига, при которых функция демонстрирует ярко выраженные локальные минимумы. Найденные почти периоды необходимо не только перечислить, но и продемонстрировать на данных: можно наложить фрагменты временного ряда друг на друга, построить графики участков, разделённых найденным сдвигом, и отметить повторяющиеся интервалы на исходном графике. В отчёте важно объяснить, насколько устойчивы найденные почти периоды и можно ли считать их содержательно значимыми.

Третий этап посвящён оценке трендовых характеристик временного ряда. Здесь требуется построить анаморфозы ограниченного и интенсивного роста. Анаморфоза – это преобразование данных, позволяющее проверить, соответствует ли участок временного ряда определённой модели роста за счёт линеаризации зависимости.

Для анализа ограниченного роста необходимо выбрать участки временного ряда, где визуально или аналитически наблюдается замедление роста. Затем выполняется преобразование данных, позволяющее проверить наличие зависимости, характерной для ограниченного роста. Если после

преобразования точки располагаются близко к прямой линии, можно сделать вывод, что выбранный участок действительно описывается моделью ограниченного роста. В отчёте следует указать границы участка, параметры роста, характер насыщения и возможный предельный уровень.

Для анализа интенсивного роста необходимо найти участки, где наблюдается ускоренное увеличение значений временного ряда. Такие участки могут соответствовать например, экспоненциальному или степенному росту. После построения соответствующей анаморфозы студент должен определить, насколько хорошо преобразованные данные аппроксимируются линейной зависимостью. Если линейность выражена явно, можно сделать вывод о наличии интенсивного роста. Результаты следует отобразить на исходном графике временного ряда, выделив соответствующие интервалы и подписав их характеристики.

В итоговой части работы студент должен представить комплексный результат анализа. В отчёт необходимо включить описание исходных данных, график временного ряда, результаты разделения быстрых и медленных движений, графики обобщённой сдвиговой функции, найденные почти периоды, примеры их проявления в данных, анаморфозы ограниченного и интенсивного роста, а также интерпретацию полученных результатов. Важно не ограничиваться формальным построением графиков: каждый результат должен сопровождаться пояснением, что он означает для исследуемого процесса.

ПРАКТИЧЕСКОЕ ЗАДАНИЕ 5. КЛАСТЕРИЗАЦИЯ ДАННЫХ

Практическое занятие направлено на закрепление навыков анализа многомерных данных без заранее заданных классов. В качестве исходной базы должен использоваться набор данных, сформированный студентами в первой практической работе.

Предполагается, что данные уже предобработаны по результатам первой практики. Таким образом, на этой основе необходимо определить признаки, которые будут использоваться для кластеризации. Не рекомендуется включать идентификаторы, текстовые поля без предварительного кодирования, а также признаки, не несущие аналитического смысла. Поскольку большинство методов кластеризации чувствительны к масштабу признаков, данные следует нормализовать или стандартизировать.

Затем требуется реализовать классические методы кластеризации (не менее трёх методов). В качестве базового набора можно выбрать метод *k*-средних, агломеративную иерархическую кластеризацию и DBSCAN.

Метод *k*-средних позволяет разделить объекты на заранее заданное число кластеров, минимизируя внутрикластерное расстояние. Для него важно подобрать число кластеров, например с помощью метода локтя или коэффициента силуэта.

Иерархическая кластеризация позволяет получить древовидную структуру объединения объектов и оценить, насколько устойчиво формируются группы.

DBSCAN полезен тем, что способен находить кластеры произвольной формы и выделять шумовые объекты, однако требует подбора параметров радиуса окрестности и минимального числа точек.

После применения каждого классического метода необходимо оценить качество кластеризации на основе известных оценок. Если размерность данных больше двух, для построения 2D-графиков следует применить методы снижения размерности, например PCA или t-SNE. На графиках необходимо отобразить объекты разными цветами в зависимости от принадлежности к кластеру. Для DBSCAN отдельно желательно показать шумовые точки, если они были обнаружены.

Полученные результаты классических методов необходимо сравнить с методом разбиения на кластеры на основе безразмерных комплексов. Его смысл заключается в переходе от исходных размерных признаков к безразмерным величинам или комплексам, которые позволяют сравнивать объекты независимо от исходных единиц измерения. Для этого признаки могут быть преобразованы через отношения, нормированные показатели, индексы или специально построенные комбинации переменных.

Важно не просто механически преобразовать данные, а объяснить, почему выбранные безразмерные комплексы отражают существенные свойства объектов. После формирования таких комплексов к ним применяется процедура разбиения на группы, а результаты также

визуализируются на 2D-графике.

После построения результатов безразмерных комплексов выполняется сравнение результатов. Необходимо сопоставить количество найденных кластеров, состав групп, наличие выбросов, компактность кластеров и интерпретируемость полученных результатов.

Студент должен определить, совпадают ли группы, найденные разными методами, какие методы дают более устойчивую структуру, а какие – более сложную или менее объяснимую. Особое внимание следует уделить сравнению классических методов с подходом на основе безразмерных комплексов: нужно показать, улучшилось ли разделение объектов после преобразования признаков, стали ли кластеры более осмысленными и удобными для интерпретации.

В отчёте по практической работе следует представить описание исходного набора данных, перечень использованных признаков, этапы предварительной обработки, параметры каждого метода кластеризации, таблицу метрик качества, графики кластеров и итоговое сравнение подходов.

В заключении необходимо указать, какой метод оказался наиболее удачным для данного набора данных и почему. Также желательно отметить ограничения анализа: зависимость результатов от масштабирования, выбора признаков, параметров алгоритмов и способа построения безразмерных комплексов.