

Практическая работа №1. Введение в инструментарий анализа данных

1. Назначение практической работы

Цель работы — освоить полный базовый цикл анализа табличных данных: подготовить воспроизводимое Python-окружение, загрузить данные, проверить их структуру и качество, выполнить предобработку, получить описательные статистики, сформировать простые аналитические срезы, визуализировать закономерности и сохранить подготовленный набор данных в обменных и аналитических форматах.

В отличие от работы, построенной вокруг отдельных конструкций языка Python, здесь синтаксис используется только как инструмент решения аналитической задачи. Каждая операция должна сопровождаться интерпретацией результата. Студент отвечает не только на вопрос «что вернула функция?», но и на вопрос «что это означает для исследуемого набора данных?».

Ожидаемые результаты обучения

- создавать изолированное окружение Python и подключать библиотеки анализа данных;
- объяснять различия между CSV, JSON и Parquet с точки зрения структуры и аналитической обработки;
- использовать DataFrame и Series, понимать типы данных и влияние dtype на память;
- применять head(), info(), describe(), isna(), duplicated(), nunique(), loc(), query(), groupby() и agg();
- выполнять векторные преобразования и создавать вычисляемые признаки;
- проводить базовый EDA: распределения, частоты, групповые статистики, корреляции и поиск потенциальных выбросов;
- выбирать базовый тип визуализации под аналитический вопрос;
- экспортировать подготовленные данные и формулировать воспроизводимые выводы.

Исходные данные

Файл FiresRu.csv¹ содержит 26 681 наблюдений и 9 признаков. В нём представлены категория события, географические координаты и набор

¹ Метеорологические условия пожаров на территории России (2021–2022) <https://data.rcsi.science/data-catalog/datasets/209/>, дата обновления: 24.04.2026

метеорологических характеристик. В файле отсутствует поле даты/времени, поэтому временной ряд по этим данным построить нельзя без внешнего источника временной информации.

Таблица 1. Описание набора данных пожаров в России

Поле	Тип	Интерпретация
<i>type_name</i>	object / category	Тип события; в файле 5 категорий.
<i>type_id</i>	int	Числовой код типа события; аналитически это категориальный код, а не непрерывная величина.
<i>lon</i>	float	Долгота.
<i>lat</i>	float	Широта.
<i>temperature_c</i>	float	Температура, °С.
<i>precipitation_mm</i>	float	Количество осадков, мм.
<i>relative_humidity</i>	float	Относительная влажность. Единица явно не задана метаданными файла.
<i>wind_speed_ms</i>	float	Скорость ветра, м/с.
<i>solar_radiation</i>	float	Показатель солнечной радиации; единица измерения в CSV не указана.

Нельзя приписывать столбцу физическую единицу, которой нет в метаданных. Например, числовой диапазон *relative_humidity* выглядит как процентная шкала, но формальный отчёт должен отделять наблюдение по данным от утверждения о единицах измерения. Для *solar_radiation* единица в файле вовсе отсутствует.

2. Рабочее окружение Python

Изолированное виртуальное окружение фиксирует набор библиотек конкретного проекта и снижает риск конфликтов версий. Для курса целесообразно

использовать один базовый интерпретатор, например Python 3.11, чтобы последующие работы с PySpark выполнялись в том же окружении. Jupyter Notebook удобен для интерактивного исследования, а VS Code позволяет выполнять тот же код в интерактивном режиме или скриптовом режиме.

Пакеты устанавливаются внутрь активированного окружения. Для этой работы нужны pandas и numpy для вычислений, matplotlib для графиков, jupyter для интерактивной работы и pyarrow для Parquet.

Практический блок 2.1. Создание окружения

В этом блоке используются команды оболочки и механизм запуска модулей Python. Команда `py -3.11` выбирает интерпретатор Python 3.11, ключ `-m` запускает указанный модуль как программу, а модуль `venv` создаёт изолированное окружение в каталоге `.venv`. После активации окружения конструкция `python -m pip` гарантирует, что менеджер пакетов относится именно к текущему интерпретатору. Ключ `--upgrade` обновляет `pip`, а перечисленные после `install` имена задают устанавливаемые пакеты. Команда `jupyter notebook` запускает локальный сервер Jupyter и открывает интерфейс Notebook в браузере.

```
# Windows PowerShell / cmd
py -3.11 -m venv .venv
.venv\Scripts\activate
python -m pip install --upgrade pip
python -m pip install pandas numpy matplotlib pyarrow jupyter

# Запуск Jupyter
jupyter notebook
```

После установки команды `import pandas`, `import numpy` и `import matplotlib` должны выполняться без `ImportError`. Номера версий будут зависеть от даты установки и поэтому в методичке не фиксируются.

Проверка окружения

```
import sys
import pandas as pd
import numpy as np
import matplotlib

print("Python:", sys.version.split()[0])
print("pandas:", pd.__version__)
print("NumPy:", np.__version__)
print("Matplotlib:", matplotlib.__version__)
```