

Таблица 6. Результат выполнения блока 6.2. в виде таблицы

type_name	wind_speed_ms	wind_speed_kmh	is_forest_fire
Natural fire	1.14	4.10	False
Natural fire	1.14	4.10	False
Forest fire	0.80	2.88	True
Natural fire	0.97	3.49	False
Natural fire	1.14	4.10	False

wind_speed_kmh — линейное преобразование единиц, а is_forest_fire — логический индикатор категории. Первый столбец не добавляет новой физической информации, но удобен для представления. Второй пригоден для фильтрации и может выступать бинарной меткой в последующих задачах.

7. Фильтрация, группировка и агрегирование

Фильтрация отвечает на вопрос «какие строки удовлетворяют условию?», а группировка — «как отличается агрегат между категориями?». В Pandas булево выражение формирует маску длины N, после чего loc выбирает строки и столбцы. Метод groupby() делит данные на группы, а agg() вычисляет несколько статистик за один проход логической операции.

Практический блок 7.1. Распределение наблюдений по типам

В следующем фрагменте будет построена таблица распределения классов: для каждого type_name определяются и число наблюдений, и его доля в процентах. Результат нужно интерпретировать не только как рейтинг частот, но и как диагностику баланса выборки.

Метод value_counts() подсчитывает частоту каждого уникального значения Series и по умолчанию сортирует категории по убыванию частоты.

to_frame("n") преобразует полученную Series в DataFrame со столбцом n.

Метод assign() добавляет вычисляемый столбец и возвращает новый DataFrame; в данном случае значение share_pct задаётся через lambda — небольшую анонимную функцию.

len(df) возвращает общее число строк, поэтому $n / \text{len}(\text{df}) * 100$ переводит абсолютные частоты в проценты.

```
type_stats = (
    df["type_name"]
    .value_counts()
    .to_frame("n")
    .assign(share_pct=lambda x: x["n"] / len(df) * 100)
```

```
)
print(type_stats.round(2))
```

Таблица 7. Результат выполнения блока 7.1 в виде таблицы

type_name	n	share_pct
Forest fire	18415	69.02
Natural fire	5195	19.47
Uncontrolled burn	2711	10.16
Controlled burn	333	1.25
Peat fire	27	0.10

Категория Forest fire составляет 69.02% всех строк (18 415 наблюдений), тогда как Peat fire — только 0.10% (27 наблюдений). Набор существенно несбалансирован по типу события. Это важно учитывать при сравнении категорий и особенно при будущей классификации.

Практический блок 7.2. Групповые средние

Код сформирует одну сравнительную таблицу, в которой для каждого типа события одновременно вычисляются объём группы и средние значения температуры, осадков, влажности, скорости ветра и солнечной радиации.

Метод `groupby("type_name")` разбивает строки на группы по типу события. Параметр `observed=True` особенно важен для категориальных типов данных поскольку он ограничивает результат реально наблюдавшимися категориями.

Метод `agg()` поддерживает именованные агрегации в форме `новое_имя=(исходный_столбец, функция)`.

Функция `size` считает число строк группы, а `mean` — среднее выбранного признака.

`sort_values("n", ascending=False)` упорядочивает итог по размеру групп от большей к меньшей.

```
group_stats = (
    df.groupby("type_name", observed=True)
      .agg(
          n=("type_name", "size"),
          temp_mean=("temperature_c", "mean"),
          precip_mean=("precipitation_mm", "mean"),
          humidity_mean=("relative_humidity", "mean"),
          wind_mean=("wind_speed_ms", "mean"),
          solar_mean=("solar_radiation", "mean")
      )
)
```

```
.sort_values("n", ascending=False)
)
print(group_stats.round(2))
```

Таблица 8. Результат выполнения блока 7.2. в виде таблицы

type_name	n	temp_mean	precip_mean	humidity_mean	wind_mean	solar_mean
Forest fire	18415	18.69	0.50	70.30	0.42	5.87
Natural fire	5195	17.42	0.40	69.07	0.80	5.14
Uncontrolled burn	2711	14.21	0.29	64.35	1.64	4.57
Controlled burn	333	10.78	0.25	69.46	1.46	4.27
Peat fire	27	18.17	0.55	65.47	1.19	5.26

В отчете при анализе результата сначала нужно смотреть на *n*, а уже затем сравнивать средние. Статистика группы из нескольких десятков наблюдений не должна трактоваться с той же уверенностью, что и статистика группы из тысяч строк. Статистика Peat fire основана только на 27 строках, поэтому прямое сравнение со статистикой для 18415 наблюдений в Forest fire неуместно. Средние описывают конкретный набор наблюдений, но сами по себе не доказывают причинную связь между погодой и типом события.

Практический блок 7.3. Условная фильтрация

Код ниже сформирует срез наблюдений, для которых одновременно выполняются два условия: влажность ниже 40 и скорость ветра выше 2 м/с. Из выбранных строк оставляются только поля, необходимые для интерпретации результата. После фильтрации программа считает объём подвыборки и показывает несколько строк. Индексатор `df.loc[условие, столбцы]` выбирает строки по логической маске и одновременно ограничивает набор возвращаемых столбцов.

Сравнения `df["relative_humidity"] < 40` и `df["wind_speed_ms"] > 2` создают две булевы Series.

Оператор `&` выполняет поэлементное логическое «И»; каждое сравнение заключается в круглые скобки из-за приоритетов операторов Pandas/Python.

Метод `len(subset)` даёт число выбранных строк, а `head()` — первые примеры.

```
subset = df.loc[
    (df["relative_humidity"] < 40) &
    (df["wind_speed_ms"] > 2),
    ["type_name", "lon", "lat", "temperature_c",
     "relative_humidity", "wind_speed_ms"]
```

```
]
print("Строк в срезе:", len(subset))
print(subset.head())
```

Результат выполнения

Строк в срезе: 337

Таблица 9. Результат выполнения блока 7.3 как таблица; результат показывает первые 5 наблюдений из подвыборки

type_name	lon	lat	temperature_c	relative_humidity	wind_speed_ms
Forest fire	91.39	51.06	15.15	27.97	2.55
Forest fire	104.58	50.37	14.67	37.89	2.64
Forest fire	104.49	50.36	14.67	37.89	2.64
Forest fire	104.42	50.33	14.67	37.89	2.64
Forest fire	104.30	50.34	14.67	37.89	2.64

Условия `relative_humidity < 40` и `wind_speed_ms > 2` выбраны только как учебный пример составного фильтра, а не как нормативный критерий пожарной опасности. В наборе им соответствуют 337 строк.

8. Корреляция и потенциальные выбросы

Коэффициент корреляции Пирсона оценивает линейную связь двух числовых признаков и лежит в диапазоне от -1 до 1 . Значение около нуля означает отсутствие выраженной линейной связи, но не отсутствие любой зависимости. Корреляция также не устанавливает причинность.

Для первичного поиска необычных значений можно использовать межквартильный размах $IQR = Q3 - Q1$. Эвристическое правило помечает значения за пределами $[Q1 - 1,5 \cdot IQR; Q3 + 1,5 \cdot IQR]$. Такие наблюдения являются кандидатами на дополнительную проверку, а не автоматически ошибками.