

Правило IQR помечает 3 652 наблюдения по скорости ветра. Такая доля слишком велика, чтобы автоматически считать эти строки ошибочными: скорее распределение имеет выраженный правый хвост. В реальном проекте решение об удалении возможно только после проверки источника и предметной интерпретации.

Такой порядок выполнения операций подчёркивает, что статистическая эвристика создаёт список для проверки, но не принимает решение об ошибочности наблюдений.

9. Визуальный разведочный анализ

График должен отвечать на конкретный аналитический вопрос. Столбчатая диаграмма удобна для сравнения категорий, гистограмма — для формы распределения одной числовой величины, график разброса — для взаимосвязи двух числовых переменных, временной ряд — для значения, упорядоченного по времени. Выбор типа графика определяется структурой данных, а не желанием использовать как можно больше визуализаций.

В таблице нет даты или времени события. Поэтому построение временного ряда «число пожаров по месяцам» на основе этого файла невозможно. Создавать искусственную дату или использовать индекс строки как время методологически неправильно.

Практический блок 9.1. Bar chart частоты типов событий

Перед построением графика частоты будут рассчитаны заново и отсортированы так, чтобы горизонтальные столбцы удобно сравнивались визуально. Полученная диаграмма предназначена не для поиска точных чисел — они уже известны из таблицы частот, — а для быстрой оценки относительных масштабов категорий и дисбаланса классов. Заголовок и подписи осей добавляются как обязательная часть аналитической визуализации.

Импорт библиотеки `import matplotlib.pyplot as plt` подключает модуль `pyplot` библиотеки `Matplotlib` под коротким именем `plt`.

Метод `value_counts()` вычисляет частоты категорий, `sort_values()` упорядочивает их, а `Series.plot(kind="barh")` использует интеграцию `Pandas` с `Matplotlib` для построения горизонтальной столбчатой диаграммы. Параметр `figsize` задаёт размер рисунка.

Методы объекта Axes `set_title()`, `set_xlabel()` и `set_ylabel()` оформляют график, `tight_layout()` корректирует поля, а `show()` выводит готовую фигуру.

```
import matplotlib.pyplot as plt

counts = df["type_name"].value_counts().sort_values()
ax = counts.plot(kind="barh", figsize=(8, 4.5))
ax.set_title("Количество наблюдений по типу события")
ax.set_xlabel("Число наблюдений")
ax.set_ylabel("Тип события")
plt.tight_layout()
plt.show()
```




Рис. 1. Столбчатая диаграмма классов для оценки дисбаланса категорий

Визуально подтверждается сильный дисбаланс: Forest fire доминирует, Peat fire представлен минимально. При построении моделей обычная ассигасу может оказаться вводящей в заблуждение, потому что доминирующий класс задаёт значительную долю правильных ответов даже у слабой модели.

Практический блок 9.2. Histogram: распределение температуры

Следующий график отвечает на вопрос о форме распределения `temperature_c`. Гистограмма позволит увидеть, где сосредоточена основная масса наблюдений, насколько распределение симметрично, имеются ли длинные хвосты или отдельные удалённые диапазоны. Число интервалов не следует воспринимать как

единственно правильное значение, поскольку внешний вид гистограммы зависит от разбиения шкалы.

Функция `plt.figure(figsize=...)` создаёт отдельную фигуру.

Функция `plt.hist()` строит гистограмму числового признака: параметр `bins=30` разбивает диапазон температуры на 30 интервалов, а высота каждого столбца показывает число наблюдений в соответствующем интервале; `edgecolor` задаёт цвет границ столбцов.

Функции `title()`, `xlabel()` и `ylabel()` задают контекст графика, `tight_layout()` уменьшает риск наложения элементов, `show()` завершает отображение.

```
plt.figure(figsize=(8, 4.5))
plt.hist(df["temperature_c"], bins=30, edgecolor="white")
plt.title("Распределение температуры")
plt.xlabel("Температура, °C")
plt.ylabel("Частота")
plt.tight_layout()
plt.show()
```




Рис. 2. Гистограмма для признака температуры

Основная масса наблюдений сосредоточена в положительном температурном диапазоне, но присутствует длинный левый хвост с отрицательными значениями до $-34,88$ °C. По одному графику нельзя объявлять эти значения ошибками. Необходима проверка происхождения наблюдений.

Практический блок 9.3. Scatter plot для температуры и влажности

Полный набор содержит более 26 тысяч точек, поэтому для учебной визуализации будет использована воспроизводимая подвыборка. Это уменьшает перегруженность графика, сохраняя общую структуру облака наблюдений. По оси X размещается температура, по оси Y — относительная влажность.

После построения нужно оценить направление, форму и плотность облака и сопоставить визуальное впечатление с числовым коэффициентом корреляции, полученным ранее.

Метод `df.sample(n=5000, random_state=42)` формирует случайную подвыборку из 5000 строк; фиксированный `random_state` делает выбор воспроизводимым при повторном запуске.

Функция `plt.scatter(x, y)` строит точечную диаграмму двух числовых переменных. Параметр `s` управляет размером маркеров, а `alpha` — прозрачностью; значение меньше 1 помогает увидеть плотные области при наложении точек. Остальные функции Matplotlib задают размер, заголовок, подписи осей и компоновку.

```
sample = df.sample(n=5000, random_state=42)

plt.figure(figsize=(8, 5))
plt.scatter(
    sample["temperature_c"],
    sample["relative_humidity"],
    s=10,
    alpha=0.35
)
plt.title("Температура и относительная влажность")
plt.xlabel("Температура, °C")
plt.ylabel("Относительная влажность")
plt.tight_layout()
plt.show()
```



Рис. 3. Парная точечная диаграмма разброса признаков влажности и температуры на подвыборке из 5000 строк

Точки образуют широкое облако без узкой линейной зависимости, что согласуется с корреляцией $r \approx -0,155$ между `temperature_c` и `relative_humidity`. При увеличении температуры в среднем наблюдается слабая тенденция к снижению влажности, однако вариативность остаётся высокой.

Практический блок 9.4. Пространственный scatter plot

В этом блоке категории событий будут нанесены на одну систему координат по долготе и широте. Группировка нужна не для агрегирования, а для раздельного построения слоёв с собственными подписями в легенде. Такая диаграмма позволяет увидеть пространственные кластеры и перекрытия типов событий. При интерпретации необходимо помнить, что координаты рисуются на обычных декартовых осях. Это разведочная визуализация геометрии точек, а не полноценная географическая карта.

Цикл `for name, part in df.groupby("type_name")` использует то, что итерация по объекту `GroupBy` последовательно возвращает пару «ключ группы, `DataFrame` этой группы».

Для каждой категории `plt.scatter()` добавляет на общую фигуру точки `lon/lat`.

Параметр `label=name` сохраняет название категории для легенды, а `plt.legend()` затем строит соответствующее обозначение. `s` и `alpha` регулируют размер и прозрачность маркеров.

```
plt.figure(figsize=(8, 5.5))
for name, part in df.groupby("type_name"):
    plt.scatter(
        part["lon"], part["lat"],
        s=6, alpha=0.35, label=name
    )

plt.xlabel("Долгота")
plt.ylabel("Широта")
plt.title("Пространственное распределение наблюдений")
plt.legend()
plt.tight_layout()
plt.show()
```




Рис. 4. Точечная диаграмма координат с цветом категории

Координаты занимают широкий диапазон долгот и широт, то есть набор пространственно неоднороден. Такой scatter plot показывает геометрию выборки, но не является картой: для географической интерпретации необходима картографическая проекция и геоданные границ регионов.