

7. Правило $1,5 \cdot \text{IQR}$ помечает значительную долю наблюдений скорости ветра как потенциальные выбросы, поэтому механическое удаление таких строк без предметной проверки недопустимо.

8. В файле отсутствует временной признак. Следовательно, анализ сезонности, динамики по месяцам или годам на основе только FiresRu.csv выполнить нельзя.

9. Координаты позволяют исследовать пространственную структуру, но корректная картографическая интерпретация требует GIS-инструментов, проекции и внешних границ территорий.

Первичный EDA не должен превращаться в последовательность вызовов функций. `head()`, `info()`, `describe()`, `groupby()`, `corr()` и графики — это инструменты проверки гипотез о структуре данных. Каждый вызов должен завершаться содержательным выводом и пониманием ограничений результата.

12. Самостоятельная работа. Анализ собственного датасета

После выполнения всех учебных блоков необходимо повторить ту же последовательность аналитики на собственном наборе данных. Датасет должен отличаться от FiresRu.csv и иметь понятный источник. Разрешены открытые государственные данные, репозитории исследовательских наборов, Kaggle/UC Irvine и иные источники при условии указания ссылки/происхождения и краткого описания лицензии или условий использования, если они опубликованы.

12.1. Минимальные требования к датасету

- не менее 500 строк и не менее 5 информативных столбцов;
- не менее двух числовых признаков;
- не менее одного категориального признака;
- желательно наличие пропусков, повторов или неоднозначных типов, чтобы предобработка была содержательной;
- если есть дата/время — привести её к `datetime` и построить временную агрегацию; если времени нет — прямо указать это ограничение и выбрать другой тип графика;
- датасет не должен содержать персональные или иные данные, использование которых нарушает требования конфиденциальности.

12.2. Обязательная последовательность работы

1. Создать отдельное виртуальное окружение или использовать базовое окружение курса; зафиксировать версии Python и библиотек.

2. Загрузить исходный файл. Если формат не CSV, объяснить особенности чтения. Для CSV явно проверить разделитель, кодировку и распознавание типов.
3. Сформировать «паспорт данных», который включает такие категории как: источник, предметная область, размер таблицы, перечень признаков и их предполагаемый смысл.
4. Выполнить базовые методы `head()`, `info()`, `describe(include="all")` или эквивалентный набор диагностик.
5. Посчитать пропуски, полные дубликаты и число уникальных значений по каждому столбцу. Обосновать каждое принятое действие с пропусками/дубликатами.
6. Проверить и при необходимости изменить `dtypes`. Сравнить память до и после хотя бы одной обоснованной оптимизации.
7. Создать минимум один вычисляемый признак с явной формулой или логическим правилом и объяснить его смысл.
8. Построить минимум один составной фильтр через `loc/quegy` и интерпретировать число полученных строк.
9. Выполнить минимум две группировки/агрегации, одна из которых должна использовать несколько агрегатных функций.
10. Исследовать не менее двух числовых признаков: описательная статистика, корреляция и один способ поиска потенциальных выбросов.
11. Построить не менее четырёх осмысленных визуализаций: категориальное сравнение, распределение, взаимосвязь и четвёртый график по структуре собственного набора. При наличии времени четвертым графиком должен быть временной ряд.
12. Экспортировать очищенный набор в CSV и Parquet; при возможности также JSON. Сравнить размеры файлов и проверить повторное чтение.
13. Сформулировать не менее пяти выводов о данных и не менее двух ограничений анализа.

12.3. Что должно быть в отчёте по самостоятельному анализу

Раздел	Содержание
1. Постановка задачи	Источник датасета, цель анализа, краткая предметная постановка.
2. Паспорт данных	Размер, признаки, <code>dtypes</code> , словарь полей.
3. Качество и предобработка	Пропуски, дубликаты, типы, преобразования и их обоснование.

Раздел	Содержание
4. EDA	Код, результаты функций, таблицы агрегатов, визуализации.
5. Интерпретация	Краткий вывод после каждого существенного блока.
6. Экспорт	CSV/Parquet, размеры, проверка повторного чтения.
7. Итог	Не менее 5 выводов и 2 ограничений исследования.

12.4. Что необходимо предоставить к сдаче работы

К сдаче работы необходимо привести:

1. Jupyter Notebook с выполненными учебными блоками по FiresRu.csv.
2. Отдельный Notebook/раздел отчёта по собственному датасету.
3. Краткие выводы после каждого аналитического блока и итоговые выводы по работе.

13. Контрольные вопросы

1. Почему dtype числового столбца не гарантирует, что признак является количественным?
2. Чем DataFrame отличается от NumPy ndarray с точки зрения схемы и типов?
3. Какие диагностические задачи решают head(), info() и describe() и почему одна функция не заменяет остальные?
4. Почему отсутствие пропусков и дубликатов ещё не означает отсутствие проблем качества данных?
5. В каких случаях category уменьшает память и почему?
6. Чем фильтрация отличается от группировки?
7. Что означает коэффициент корреляции около нуля? Какие выводы из него делать нельзя?
8. Почему правило IQR нельзя использовать как автоматический алгоритм удаления данных?
9. Как выбрать между histogram, bar chart, scatter plot и временным рядом?
10. Почему временной ряд нельзя строить по индексу строк, если индекс не является временем?
11. Какие преимущества Parquet даёт аналитическому pipeline по сравнению с CSV?